

Deteksi Stance pada Opini Publik Indonesia terhadap Kasus Pelecehan Seksual di Media Sosial: Perbandingan Machine Learning, BiLSTM, dan Transformer

Yuma Hazza Yuditama¹, Raihan Lazuardi², Muhammad Akmal Fazli Riyadi³

^{1,2,3}Fakultas Sains dan Matematika, Universitas Diponegoro, Indonesia



Pihak Kompetisi Data Mining:



ABSTRAK

Belakangan ini, banyak isu pelecehan seksual yang beredar di lingkungan pendidikan. Khususnya adalah kasus terbaru yang melibatkan mahasiswa Fakultas Hukum Universitas Indonesia pada awal April 2026. Kasus ini sangat ramai dibahas di media sosial. Banyak netizen-netizen yang mengomentari kasus tersebut dengan berbagai perspektif. Ada yang mendukung korban, mengkritik institusi pendidikan, berkomentar netral, bahkan mendukung pelaku. Dari kasus ini, hadirilah eksperimen ini untuk menganalisis kecenderungan komentar netizen terhadap kasus tersebut atau dengan kata lain analisis sentimen. Kami telah mengumpulkan sebanyak 1500 data teks dari opini publik pada platform media sosial Tiktok dan Youtube. Kami melakukan klasifikasi terhadap data teks tersebut menjadi empat kategori yaitu: *Supportive*, *Victim Blaming*, *Advocacy*, dan *Neutral*. Eksperimen ini melibatkan model *machine learning* konvensional seperti Multinomial Naive-Bayes dan SVM, serta model *advance* seperti Bi-LSTM dan Transformer. Kami membandingkan performa antara empat model tersebut. Hasil eksperimen ini menunjukkan bahwa model IndoBERTTweet memiliki tingkat akurasi sebesar 0.7967 dan skor F1-Macro sebesar 0.5708. Model ini lebih unggul dibandingkan model lain karena kemampuannya memahami kompleksitas bahasa Indonesia, khususnya bahasa gaul atau bahasa khas netizen Indonesia. Sehingga, model ini efektif untuk memilah komentar-komentar netizen Indonesia yang beragam di berbagai media sosial.

Kata Kunci: *Pelecehan Seksual, Analisis Sentimen, Multinomial Naive-Bayes, SVM, Bi-LSTM, IndoBERTTweet, Media Sosial, Opini Publik.*

1. Pendahuluan

1.1. Latar Belakang

Fenomena kekerasan seksual saat ini telah menjadi isu mendesak yang menyentuh berbagai ranah kehidupan, mulai dari lingkungan domestik hingga institusi akademik. Secara khusus, peristiwa pelecehan verbal yang menyeret oknum mahasiswa Fakultas Hukum Universitas Indonesia pada April 2026 menjadi pemantik gelombang reaksi besar di ruang digital. Mengingat latar belakang pelaku yang menempuh pendidikan hukum, masyarakat di platform TikTok dan YouTube bereaksi dengan tingkat keterlibatan emosional yang sangat tinggi.

Namun, menganalisis ribuan opini tersebut secara manual merupakan tantangan besar karena sifat data media sosial yang sangat acak, penuh dengan penggunaan istilah gaul (*slang*), serta memiliki ketidakseimbangan kelas yang tajam dalam distribusinya. Oleh sebab itu, penerapan teknologi *stance detection* melalui pendekatan *Machine Learning* dan *Transformer* menjadi solusi krusial untuk membedah secara presisi bagaimana publik memposisikan diri—apakah cenderung mendukung, memberikan advokasi, atau justru terjebak dalam pola *victim blaming* terhadap isu sensitif ini.

1.2. Tujuan

- 1.2.1. Melakukan pemetaan otomatis terhadap opini publik terkait kasus pelecehan seksual ke dalam empat kategori: Supportive, Victim Blaming, Advocacy, dan Neutral.
- 1.2.2. Menguji dan membandingkan ketangguhan performa antara algoritma *Machine Learning* (ComplementNB, SVM), *Deep Learning* (BiLSTM), serta model *Transformer* (IndoBERT dan IndoBERTTweet)
- 1.2.3. Menganalisis sejauh mana integrasi fitur tambahan seperti leksikon emosi dan leksikon khusus *victim blaming* dapat mengoptimalkan kemampuan model dalam mengenali pola data yang sangat tidak seimbang.

1.3. Manfaat

- 1.3.1. Memperkaya khazanah riset *Natural Language Processing* (NLP) untuk bahasa Indonesia, khususnya dalam memproses teks media sosial yang penuh dengan bahasa tidak baku dan isu sensitif.

1.4. Batasan

- 1.4.1. Sumber Data: Data hanya dihimpun melalui proses *scraping* dari platform video pendek TikTok dan platform YouTube.
- 1.4.2. Kategori Stance: Proses klasifikasi hanya dilakukan terhadap empat kategori posisi opini yang telah ditentukan di awal penelitian.

- 1.4.3. Fokus Kasus: Objek pengamatan dibatasi pada diskursus mengenai dugaan pelecehan seksual verbal oleh mahasiswa FH UI yang terjadi pada periode April 2026.
- 1.4.4. Volume Dataset: Penelitian ini hanya mengolah sebanyak 1.500 baris teks komentar.
- 1.4.5. Karakteristik Bahasa: Teks yang dianalisis mencakup bahasa Indonesia formal maupun ragam bahasa informal (*slang* dan singkatan).

2. Metodologi

2.1. Deskripsi Dataset

Penelitian ini menggunakan dataset dari hasil *scraping* melalui media sosial Tiktok dan Youtube. Dataset total berjumlah 1500 teks yang dibagi menjadi 4 kategori, yaitu Victim Blaming, Supportive, Advocacy, dan Neutral. Kategori Victim Blaming terdapat 53 teks, Supportive terdapat 129 teks, Advocacy terdapat 210 teks, dan Neutral terdapat 1108 teks. Distribusi dataset dapat dilihat pada gambar berikut.



2.2. Tahapan Preprocessing

Tahap preprocessing dalam penelitian ini ada dua tahap yaitu proses pembersihan data dan proses encode pada kategori. Proses pembersihan data yang pertama ini bertujuan menormalisasikan tekstual asli menjadi teks yang mudah dibaca dan sesuai dengan kamus bahasa Indonesia yang benar. Seperti teks “gk” akan diubah menjadi “tidak”, “sdh” menjadi “sudah”, “krn” menjadi karena”. Selain itu proses ini juga mengimplementasikan stopword dan penghapusan emoji dan teks-teks yang tidak ada dalam kamus bahasa Indonesia. Berikut dapat dilihat hasil seperti pada gambar berikut.

	text	stance		
0	udh bener di UGM aja lah	Neutral		
1	jurusan hukum ✖npraktek hukum ✔	Neutral		
2	Ini masalah rusaknya moral, bukan hal yang sep...	Advocacy		
3	DO aja semuanya	Advocacy		
4	Usut tuntas proses hukum dan pecat mahasiswa b...	Advocacy		



	text	stance	panjangData	CleanText
0	udh bener di UGM aja lah	Neutral	24	bener ugm
1	jurusan hukum ✖npraktek hukum ✔	Neutral	31	jurusan hukum praktek hukum
2	Ini masalah rusaknya moral, bukan hal yang sep...	Advocacy	179	masalah rusaknya moral bukan sepele emoji tert...
3	DO aja semuanya	Advocacy	15	drop out semuanya
4	Usut tuntas proses hukum dan pecat mahasiswa b...	Advocacy	50	usut tuntas proses hukum pecat mahasiswa bejat

2.3. Feature Engineering

2.3.1. TF-IDF (Naive Bayes dan SVM)

TfidfVectorizer diatur dengan parameter `max_features = 5000` dan `ngram_range = (1,2)` sehingga menghasilkan unigram dan bigram. Vectorizer dilatih hanya di data training dan ditransformasi ke data validasi untuk menghindari terjadi nya data leakage.

2.3.2. TF-IDF (Naive Bayes dan SVM)

Tiga kategori emosi dibuat dengan *lexicon* manual, yaitu kategori marah yang terdiri dari kata seperti marah, bejat, biadab, hancur, benci, emosi, kecewa, dendam, jengkel, dan tega. Kategori sedih terdiri dari kata seperti sedih, miris, kasihan, trauma, menangis, duka, prihatin, nyesek, sakit hati, dan nyelekit. Kategori takut yang terdiri dari kata takut, ngeri, ancam, waspada, khawatir, dan hati-hati. Proses ekstrasi fitur dilakukan dengan menghitung jumlah kemunculan *substring* dari setiap kata dalam *lexicon* pada teks. Perhitungan menghasilkan vektor dimensi tiga yang memunculkan masing-masing kategori emosi, kemudian metode hstack digunakan untuk menggabungkan dengan matriks TF-IDF

2.3.3. Victim-Blamming Lexicon Feature (SVM + VB Lexicon)

Lexicon victim blaming terdiri dari 15 kata, yaitu pakain, baju, ketat, salahnya, godain, malam, sendirian, terbuka, provokatif, rok, goda, rayuan, salah sendiri, minta, dan wajar. Proses ekstrasi fitur dihitung dengan jumlah kemunculan kata *victim blaming* di teks dan menghasilkan skor tunggal vektor dimensi satu, setelah itu metode hstack digunakan untuk menggabungkan vektor tersebut.

2.3.4. Penanganan Class Imbalance (semua model)

Semua model menggunakan *class weighting* untuk menjaga keseimbangan distribusi semua label. Pada model SVM digunakan parameter `classweight='balanced'` pada konstruktor SVC. Pada model BiLSTM digunakan fungsi `compute_class_weight(class_weight='balanced')` dari scikit-learn, dan hasilnya diberikan sebagai parameter `class_weight` pada proses `model.fit()`. Pada model IndoBERT dan IndoBERTTweet digunakan `compute_class_weight` dari scikit-learn dan diubah menjadi `torch.tensor` dengan tipe `torch.float`. Bobot tersebut dipakai di dalam CustomTrainer yang melakukan *override* terhadap fungsi `compute_loss` menggunakan `nn.CrossEntropyLoss(weight=weight)`.

2.4. Arsitektur Model

2.4.1. ComplementNB + TF-IDF

ComplementNB digunakan untuk model *baseline* dari NaiveBayes. Jika dibandingkan dengan MultinomialNB, metode ini lebih tahan terhadap distribusi kelas yang tidak seimbang (*data imbalanced*) karena estimasi parameternya dihitung dengan komplement dari masing-masing kelas.

2.4.2. SVM Linear + Variasi Fitur

Scikit-Learn SVC dengan parameter `kernel='linear'` dan `class_weight='balanced'` dioptimalkan memakai GridSearchCV dengan `cv=3` dan `scoring='f1_macro'`. Pencarian parameter dilakukan dengan nilai `c = [0.01, 0.1, 1, 10]`. GridSearchCV diproses secara terpisah pada tiga bagian yaitu hanya menggunakan TF-IDF sebagai *baseline*, gabungan TF-IDF dengan *emotion feature* memakai metode `hstack`, dan gabungan TF-IDF dengan *lexicon victim blaming* memakai `hstack`.

2.4.3. BiLSTM + Embedding

Keras arsitektur model dibuat dengan Keras Functional API dengan konfigurasi parameter meliputi `VOCAB_SIZE=10.000`, `MAX_LEN=100`, `EMBED_DIM=128`, `LSTM_UNITS=64`, `DROPOUT_RATE=0.4`, `BATCH_SIZE = 32`, dan `EPOCHS=30`.

Layer	Output Shape	BiLSTM+ Embedding	BiLSTM+Embedding+Attention
Input	(batch, 100)	✓	✓
Embedding	(batch, 100, 128)	✓	✓
Bidirectional LSTM	(batch, 100, 128)	return_sequences=True	return_sequences=True
GlobalMaxPooling1D	(batch, 128)	✓	× (Diganti Attention)
AttentionLayer (custom)	(batch, 128)	×	✓
Dropout (rate=0.4)	(batch, 128)	✓	✓
Dense (ReLU, units=64)	(batch, 64)	✓	✓
Dense (Softmax, units=4)	(batch, 64)	✓	✓

Perbandingan utama antar dua jenis model BiLSTM terdapat di mekanisme agregasi output sekuens. Model pertama menggunakan GlobalMaxPooling1D, sedangkan model kedua diganti dengan AttentionLayer kustom yang mempelajari bobot konteks melalui mekanisme attention Bahdanau dengan parameter terlatih berupa w , b , dan u . Proses pelatihan model dilakukan dengan optimizer Adam dengan learning rate $1e-3$ dan fungsi loss `categorical_crossentropy`. Selain itu, digunakan dua callback, yaitu `EarlyStopping` dengan konfigurasi `monitor='val_loss'`, `patience=5`, dan `restore_best_weights=True`, serta `ReduceLROnPlateau` dengan parameter `monitor='val_loss'`, `factor=0.5`, `patience=3`, dan `min_lr=1e-6`.

2.4.4. IndoBERT Base dan IndoBERTTweet

Kedua model memakai AutoModelForSequenceClassification dengan konfigurasi num_labels=4. Proses tokenisasi dilakukan dengan tokenizer bawaan dari masing-masing model dengan konfigurasi MAX_LENGTH=128, padding='max_length', dan truncation=True. Dataset diproses menggunakan datasets.Dataset.from_pandas() dari Hugging Face Datasets, kemudian diimplementasikan proses mapping secara batched untuk meningkatkan efisiensi pemrosesan data.

Parameter	IndoBERT Base	IndoBERTTweet
Model Checkpoint	indolem/indobert-base-uncased	indolem/indoberttweet-base-uncased
Max sequence length	128	128
Batch size (train & eval)	16	16
Max epochs	15	15
LR scheduler	cosine	cosine
Warmup ratio	0.1	0.1
Weight decay	0.01	0.01
Early stopping patience	3 epoch (val F1 macro)	3 epoch (val F1 macro)
Loss function	CrossEntropy + class weights	CrossEntropy + class weights
Best model selection metric	f1_macro	f1_macro (↑)

Custom Trainer digunakan kedua model yang melakukan override terhadap fungsi compute_loss untuk mengimplementasikan CrossEntropyLoss berbobot kelas (class-weighted). Pemilihan checkpoint model terbaik

berdasarkan pada nilai `f1_macro` tertinggi pada validation set dengan konfigurasi `load_best_model_at_end=True`. Pada notebook IndoBERT juga digunakan fungsi `predict_stance()` untuk melakukan inferensi pada teks baru, di mana teks mentah diproses lebih dahulu melalui pipeline `final()` sebelum dimasukkan ke model.


2.4.5. Evaluasi Matrik

Terdapat perbedaan metrik evaluasi yang ada di masing-masing kelompok model. Untuk model Naive Bayes, SVM, IndoBERT, dan IndoBERTweet, metrik yang digunakan meliputi Accuracy, Balanced Accuracy, F1-Macro, F1-Weighted, Cohen's Kappa, Classification Report per kelas, serta Confusion Matrix. Sementara itu, pada kedua model BiLSTM, evaluasi meliputi Accuracy, F1-Macro, F1-Weighted, Classification Report per kelas, dan Confusion Matrix. Metrik Balanced Accuracy dan Cohen's Kappa tidak dihitung pada implementasi notebook BiLSTM. Di antara seluruh metrik yang digunakan, F1-Macro digunakan sebagai metrik utama untuk perbandingan performa model karena lebih adil untuk dataset yang tidak seimbang. Hal ini disebabkan setiap kelas memperoleh bobot yang sama tanpa dipengaruhi oleh jumlah frekuensi datanya.


3. Hasil Eksperimen dan Pengujian

3.1. Statistik Dataset

Perbandingan Opini Publik Indonesia Terhadap Kasus Kekerasan Seksual di Media Sosial




Distribusi label pada dataset menunjukkan ketidakseimbangan kelas (*class imbalance*), di mana kelas *Neutral* mendominasi jumlah data dibandingkan kelas lainnya. Jumlah data pada masing-masing kelas terdiri dari 1108 (73,9 %) data *Neutral*, 210 (14,0 %) data *Advocacy*, 129 data (8,6 %) *Supportive*, dan 53 (3,5 %) data *Victim Blaming*. Dominasi kelas *Neutral* menunjukkan bahwa sebagian besar pengguna media sosial cenderung memberikan komentar yang bersifat informatif atau umum dibandingkan komentar yang secara eksplisit mendukung korban maupun menyalahkan korban.



Selain distribusi label, dilakukan juga analisis statistik panjang teks komentar untuk melihat karakteristik data pada tiap kelas. Berdasarkan visualisasi histogram distribusi panjang teks dan boxplot panjang teks per kelas, mayoritas komentar memiliki panjang teks yang relatif pendek. Namun, terdapat beberapa komentar dengan panjang yang sangat tinggi (*outlier*), terutama pada kelas *Supportive* dan *Neutral*. Kelas *Victim Blaming* dan *Advocacy* cenderung memiliki median panjang teks yang lebih tinggi dibandingkan kelas lainnya, yang menunjukkan bahwa komentar pada kedua kategori tersebut umumnya disampaikan dalam bentuk opini yang lebih panjang dan argumentatif.

Untuk memastikan konsistensi proses pelabelan data, dilakukan pengukuran *inter-annotator agreement* menggunakan metode Fleiss' Kappa. Pada proses ini, 100 data awal dari ketiga hasil pelabelan dibuat memiliki isi komentar yang sama sebagai sampel evaluasi, sedangkan data lainnya berbeda pada masing-masing annotator. Pendekatan tersebut dilakukan untuk mengukur tingkat kesepakatan antar pelabel terhadap data yang sama. Hasil perhitungan menunjukkan nilai Fleiss' Kappa sebesar 0,9119 yang termasuk dalam kategori *almost perfect agreement*. Nilai tersebut menunjukkan bahwa proses pelabelan yang dilakukan memiliki tingkat konsistensi

yang sangat tinggi antar annotator sehingga dataset dinilai cukup reliabel untuk digunakan pada tahap eksperimen model.



Setelah tahap *preprocessing* selesai dilakukan, dataset kemudian dibagi menjadi data latih (*training set*) dan data validasi (*validation set*). Jumlah data yang digunakan pada proses pelatihan model sebanyak 1192 data, sedangkan data validasi sebanyak 298 data. Pembagian data ini dilakukan untuk memastikan model dapat dievaluasi pada data yang tidak digunakan selama proses pelatihan sehingga performa model dapat diukur secara lebih objektif.

3.2. Perbandingan Performa Model

Model	Accuracy	Balanced Accuracy	F-1 Macro	F-1 Weighted	Kappa
ComplementNB + TF-IDF	0,7047	0,4278	0,4305	0,7021	0,3072
SVM + TF-IDF (Baseline)	0,7114	0,4892	0,4753	0,7137	0,3637
SVM + TF-IDF + Emotion	0,7315	0,5093	0,4964	0,7317	0,4004
SVM + TF-IDF + VB Lexicon	0,7148	0,5381	0,5212	0,7216	0,3818
BiLSTM + Embedding	0,6980	-	0,5305	0,7147	-
BiLSTM + Emb + Attention	0,1074	-	0,0955	0,0448	-

IndoBERT Base	0,7500	0,5199	0,5168	0,7471	0,4353
IndoBERTweet	0,7967	0,5648	0,5708	0,7923	0,5216

Pada data validasi, IndoBERTweet memberikan performa terbaik dengan akurasi 0,7967, balanced accuracy 0,5648, F1-macro 0,5708, F1-weighted 0,7923, dan Cohen's Kappa 0,5216. Model ini dapat memahami pola sentimen dan stance dari tiap komentar dengan lebih baik daripada model lainnya karena model ini sudah pre-trained terhadap karakteristik bahasa Indonesia pada media sosial. IndoBERT Base menempati posisi kedua dengan akurasi 0,7500 dan F1-weighted 0,7471, tetapi performanya masih di bawah IndoBERTweet.

Pada model *machine learning*, SVM + TF-IDF + *Emotion* mendapatkan hasil terbaik dengan akurasi 0,7315 dan F1-weighted 0,7317. Hasil tersebut lebih tinggi dibanding SVM + TF-IDF *baseline* dengan akurasi sebesar 0,7114. Penambahan VB Lexicon menghasilkan peningkatan pada balanced accuracy (0,5381) dan F1-macro (0,5212). Meskipun begitu, akurasi keseluruhan tetap lebih rendah dibanding varian emotion. ComplementNB + TF-IDF menunjukkan performa paling rendah dalam kategori ini dengan akurasi 0,7047 dan Kappa 0,3072.

Pada model *deep learning*, BiLSTM + Embedding menghasilkan performa yang baik dengan akurasi 0,6980, F1-macro 0,5305, dan F1-weighted 0,7147. Sebaliknya, penambahan mekanisme *attention* pada BiLSTM justru menurunkan performa secara signifikan dengan akurasi turun menjadi 0,1074, F1-macro 0,0955, dan F1-weighted 0,0448. Penurunan yang drastis ini kemungkinan karena adanya masalah atau kesalahan pada konfigurasi atau proses pelatihan dengan *model attention*.

Berdasarkan hasil evaluasi keseluruhan, urutan performa model dari terbaik hingga terburuk adalah: IndoBERTweet, IndoBERT Base, SVM + TF-IDF + Emotion, SVM + TF-IDF + VB Lexicon, SVM + TF-IDF (Baseline), ComplementNB + TF-IDF, BiLSTM + Embedding, dan BiLSTM + Attention. Catatan: metrik Balanced Accuracy dan Cohen's Kappa tidak dihitung dalam pelatihan model BiLSTM sehingga ditandai dengan tanda strip pada tabel hasil evaluasi.

3.3. Efek Feature Engineering Tiap Model

Pada penelitian ini, penggunaan *feature engineering* dilakukan untuk mengetahui bagaimana efek fitur terhadap performa dari tiap model. Penggunaan *feature engineering* tersebut dilakukan secara berbeda-beda pada model *machine learning* tradisional, *deep learning*, dan *transformer*. Secara garis besar, hasil eksperimen menunjukkan bahwa kualitas dari tiap fitur memiliki pengaruh yang signifikan terhadap kemampuan model dalam memahami konteks atau isi komentar media sosial.

3.3.1. Model Machine Learning

Pada model *machine learning*, *feature engineering* utama yang digunakan, yaitu TF-IDF dengan tambahan *emotion feature* dan *victim blaming lexicon feature* untuk meningkatkan kemampuan model dalam mengenali pola bahasa pada komentar.

Pada model SVM + TF-IDF *baseline* mendapatkan akurasi sebesar 0,7114 dan F1-macro sebesar 0,4753. Setelah ditambahkan *emotion feature*, performa model meningkat dengan accuracy sebesar 0,7315 dan F1-macro sebesar 0,4964. Hasil ini menunjukkan bahwa informasi emosi yang ada pada komentar dapat membantu model dalam mengklasifikasikan *stance* komentar.

Sementara itu, penambahan *victim blaming lexicon feature* pada model SVM menghasilkan balanced accuracy tertinggi di antara model *machine learning* lainnya, yaitu sebesar 0,5381 dan F1-macro sebesar 0,5212. Hal ini menunjukkan bahwa kamus kata khusus *victim blaming* membantu model mengenali kelas minoritas yang sulit diprediksi karena ketidakseimbangan data.

Pada model ComplementNB + TF-IDF menghasilkan performa yang paling rendah dengan accuracy sebesar 0,7047 dan Cohen's Kappa sebesar 0,3072. Secara keseluruhann, penambahan fitur emosi dan leksikon pada mampu meningkatkan performa model *machine learning*, terutama pada balanced accuracy dan F1-Macro.

3.3.2. Mode Deep Learning

Pada model deep learning, feature engineering menggunakan word embedding untuk memahami hubungan semantik antar kata. Model BiLSTM + Embedding memperoleh accuracy sebesar 0,6980, F1-macro sebesar 0,5305, dan F1-weighted sebesar 0,7147. Hasil tersebut menunjukkan bahwa embedding cukup efektif dalam memahami konteks komentar media sosial.

Penambahan mekanisme *attention* pada BiLSTM dapat menurunkan performa dengan accuracy hanya sebesar 0,1074 dan F1-macro sebesar 0,0955. Penurunan performa ini kemungkinan disebabkan karena ukuran dataset yang terbatas, ketidakseimbangan kelas, atau konfigurasi model yang belum optimal.

Secara keseluruhan, penggunaan embedding mampu meningkatkan performa model yang pemahaman konteks, tetapi penambahan arsitektur yang lebih kompleks tidak selalu memberikan performa yang lebih baik.


3.3.3. Model Transformer

Pada model *transformer*, *feature engineering* dilakukan secara otomatis melalui *contextual embedding* dan mekanisme *self-attention*. Model IndoBERT Base mendapatkan accuracy sebesar 0,7500 dan F1-macro sebesar 0,5168. Hal tersebut menunjukkan kemampuan yang baik dalam memahami konteks bahasa Indonesia. Sementara itu, IndoBERTweet menjadi model terbaik dengan accuracy sebesar 0,7967, balanced accuracy sebesar 0,5648, F1-macro 0,5708, F1-weighted sebesar 0,7923, dan Cohen's Kappa sebesar 0,5216.

Performa IndoBERTweet yang lebih tinggi menunjukkan bahwa model yang dilatih khusus pada data media sosial lebih baik dalam memahami bahasa informal, singkatan, dan slang. Secara keseluruhan, model *transformer* memberikan performa terbaik dibandingkan pendekatan lainnya untuk mengklasifikasikan *stance* pada komentar media sosial berbahasa Indonesia.

3.4. Analisis Training Curve Tiap Model


3.4.1. Training Curve Model Machine Learning



Dari grafik *training curve*, semua model machine learning menunjukkan pola yang cukup stabil secara umum. Pada ComplementNB + TF-IDF, *training score* cenderung tinggi dan konsisten, sementara *validation score* naik perlahan seiring bertambahnya data latih. Meski demikian, gap yang cukup lebar antara keduanya mengindikasikan model masih sedikit *overfitting*.

Berbeda dengan ComplementNB, SVM + TF-IDF *baseline* menunjukkan peningkatan *validation score* yang lebih baik. Hal itu menandakan kemampuan generalisasi yang lebih baik. Ketika fitur *emotion* dan *victim blaming* ditambahkan, *validation score* kembali naik secara bertahap. Penambahan fitur-fitur ini tampaknya membantu model dalam mengenali pola bahasa pada komentar, sehingga klasifikasi menjadi lebih akurat, khususnya pada kelas minoritas. Secara keseluruhan, SVM terbukti lebih stabil dibanding ComplementNB dalam eksperimen ini.


3.4.2. Training Curve Model Deep Learning



Pada BiLSTM + Embedding, *training accuracy* naik secara konsisten hingga mendekati 1,0, sementara *validation accuracy* cenderung stagnan di sekitar 0,70. *Training loss* pun terus turun sepanjang pelatihan. Pola ini menunjukkan model cukup berhasil mempelajari data latih, tetapi selisih yang cukup besar antara *training* dan *validation accuracy* di epoch-epoch akhir mengindikasikan adanya *overfitting*.

Sementara itu, BiLSTM + Embedding + Attention memperlihatkan pola pelatihan yang jauh lebih tidak stabil. *Validation accuracy* sempat naik di awal, tetapi kemudian turun tajam pada epoch berikutnya yang diikuti dengan lonjakan *validation loss* yang cukup signifikan. Hal ini mengindikasikan model *attention* kesulitan melakukan generalisasi pada dataset yang digunakan. Penyebabnya kemungkinan berkaitan dengan jumlah data yang terbatas atau konfigurasi model yang belum tepat.

3.4.3. Training Curve Model Transformer




Pada model transformer, IndoBERT Base dan IndoBERTweet menunjukkan pola pelatihan yang cukup baik pada awal epoch. Nilai *validation* F1-macro meningkat secara bertahap hingga mencapai titik terbaik di tengah proses pelatihan. Namun, setelah beberapa epoch, *validation loss* mulai meningkat yang menandakan adanya indikasi *overfitting*.


Model IndoBERTweet memperoleh performa yang lebih stabil dibanding IndoBERT Base. Hal ini terlihat dari nilai *validation* F1-macro yang lebih tinggi dan cenderung konsisten pada beberapa epoch terakhir. Selain itu, IndoBERTweet mampu mempertahankan performa validasi lebih baik meskipun *validation loss* meningkat. Kondisi tersebut menunjukkan bahwa model yang telah dilatih khusus pada data media sosial lebih efektif dalam memahami pola bahasa informal pada komentar TikTok dan YouTube.

3.5. Analysis Error


3.5.1. Confusion Matrix Model Machine Learning



3.5.2. Confusion Matrix Model Deep Learning



3.5.3. Confusion Matrix Model Transformer



4. Analisis dan Pembahasan Hasil

4.1. Perbandingan Lintas Paradigma

Dari delapan model yang diuji, IndoBERTweet keluar sebagai yang terbaik dengan F1-macro 0.5708 dan accuracy 0.7967. Selisih 5.4 poin F1-macro terhadap IndoBERT Base (0.5168) bukan angka kecil untuk tugas klasifikasi empat kelas, dan perbedaan ini paling mencolok pada kelas *Advocacy* dengan IndoBERTweet mencatat F1 0.705 sementara IndoBERT Base hanya 0.582. Ini masuk akal secara teknis: IndoBERTweet dilatih pada korpus Twitter berbahasa Indonesia yang secara karakter lebih dekat dengan komentar media sosial informal, sehingga representasi yang dihasilkan lebih tepat untuk menangkap gaya bahasa seruan dan desakan yang khas pada kelas *Advocacy*.

Yang menarik justru terjadi di luar *Transformer*. BiLSTM standar (F1-macro 0.5305) melampaui IndoBERT Base (0.5168), dan SVM+VB Lexicon (0.5212) juga unggul tipis atas IndoBERT Base. Dua model yang jauh lebih sederhana ini mampu menggeser *Transformer* berskala besar yang berarti sebuah hasil yang tidak lazim dan patut dimaknai dengan hati-hati. Penjelasan yang paling masuk akal adalah ukuran dataset: dengan kelas *Victim Blaming* yang hanya mencakup sekitar 3.4% dari total data, *fine-tuning* IndoBERT Base kemungkinan tidak mendapat sinyal yang cukup untuk kelas-kelas minoritas, sementara BiLSTM yang dilatih dari nol justru belajar pola sekuensial yang lebih langsung dari data itu sendiri.

Soal kelas *Victim Blaming*, tidak ada model yang benar-benar memuaskan, tetapi ada perbedaan yang signifikan antar model. BiLSTM mencatat recall tertinggi sebesar 0.50, artinya satu dari dua sampel *Victim Blaming* berhasil dikenali, meskipun dengan precision yang rendah (0.278) yang berarti banyak *false positive*. SVM+VB Lexicon menghasilkan keseimbangan yang lebih baik antara precision (0.333) dan recall (0.300), dengan F1 0.316 untuk kelas ini. Yang mengejutkan, IndoBERT Base dan IndoBERTweet keduanya hanya mencapai recall 0.182 untuk *Victim Blaming*, lebih rendah dari SVM+VB Lexicon. Ini memperkuat argumen bahwa untuk kelas dengan representasi sangat minim, lexicon berbasis domain yang dirancang secara targeted bisa menandingi bahkan melampaui model yang jauh lebih besar.

Penambahan fitur emosi pada SVM (F1-macro 0.4964) memberikan peningkatan dibanding *baseline* (0.4753), tetapi tidak menggerakkan jarum sama sekali pada kelas *Victim Blaming*, recall tetap 0.10 persis sama dengan *baseline*. Ini mengungkap satu hal penting: ekspresi emosional seperti marah atau sedih tidak unik untuk *Victim Blaming*. Komentar bernada marah bisa datang dari pendukung korban yang geram, dari pelaku *victim blaming*, maupun dari pengamat yang frustrasi. Emosi tidak cukup sebagai sinyal pembeda. Sebaliknya, VB Lexicon bekerja lebih baik justru karena kata-katanya spesifik pada perilaku menyalahkan, bukan pada emosi yang menyertainya.

Satu catatan terakhir yang krusial: perbedaan besar antara accuracy (0.70–0.80) dan balanced accuracy (0.43–0.56) di semua model mengungkap bahaya membaca angka accuracy secara naif pada data yang tidak seimbang. ComplementNB misalnya mencatat accuracy 0.7047 yang tampak lumayan, tetapi balanced accuracy-nya hanya 0.4278 yang, berarti selisih 0.277 poin. Ini berarti model tersebut sebagian besar hanya pintar menebak kelas *Neutral* yang dominan, bukan benar-benar memahami distribusi stance secara menyeluruh. Dalam konteks penelitian ini, F1-macro dan balanced accuracy adalah metrik yang lebih jujur untuk menilai seberapa baik model bekerja pada seluruh kelas.

4.2. Kebaruan Penelitian

Penelitian ini memiliki empat aspek kebaruan yang membedakannya dari penelitian sebelumnya.

- Pertama, penerapan *stance-based labeling* empat kelas, antara lain *Supportive*, *Victim Blaming*, *Neutral*, dan *Advocacy* pada domain kekerasan seksual berbahasa Indonesia di media sosial. Granularitas ini melampaui pendekatan sentimen tiga kelas yang lazim, karena mampu membedakan dua respons afirmatif yang berbeda secara substantif: dukungan emosional terhadap korban (*Supportive*) versus desakan perubahan struktural dan kebijakan (*Advocacy*). Perbedaan ini penting secara sosial namun kerap luput dari sistem berbasis sentimen konvensional.
- Kedua, pengembangan *victim-blaming lexicon* berbasis bahasa informal Indonesia dengan 15 kata diskriminatif, dilengkapi *emotion lexicon* tiga kategori (marah, sedih, takut) dengan total 26 kata. Hasil eksperimen

membuktikan kontribusi nyata lexicon ini: SVM+VB Lexicon mencapai F1-macro 0.5212 dan recall kelas *Victim Blaming* sebesar 0.30, menjadikannya satu-satunya model ML klasik yang berhasil mendeteksi kelas tersebut secara bermakna. Lebih jauh, SVM+VB Lexicon bahkan melampaui IndoBERT Base (F1-macro 0.5168) dalam metrik keseluruhan, menunjukkan bahwa sinyal leksikal berbasis domain yang dirancang secara targeted mampu bersaing dengan model *Transformer* berskala besar ketika data terbatas.

- Ketiga, perbandingan multilayer komprehensif delapan model dari tiga paradigma NLP dalam satu studi dengan dataset, *split*, dan metrik yang konsisten. Perbandingan ini menghasilkan temuan yang secara empiris menantang asumsi umum: BiLSTM tanpa attention (F1-macro 0.5305) mengungguli IndoBERT Base (0.5168), dan BiLSTM mencatat recall tertinggi untuk kelas *Victim Blaming* (0.50) di antara semua model yang diuji termasuk kedua *Transformer*. Ini mengindikasikan bahwa pada dataset kecil dengan distribusi kelas yang sangat tidak seimbang, representasi sekuensial yang dilatih langsung pada data domain kadang lebih efektif dibandingkan *fine-tuning* model generik.
- Keempat, *pipeline preprocessing* yang dirancang secara berbeda antar paradigma sesuai karakteristik arsitekturnya. Model Transformer mempertahankan informasi emosi dari emoji melalui emoji.demojize() serta tanda baca, sementara model non-Transformer menggunakan representasi teks bersih berbasis ASCII. Keputusan desain ini mencerminkan kesadaran bahwa model *pre-trained* dilatih pada teks yang mempertahankan konteks pragmatik, sehingga menghapus informasi tersebut justru berpotensi menurunkan kualitas representasi.

4.3. Keterbatasan

Berdasarkan hasil eksperimen aktual, terdapat beberapa keterbatasan substantif yang perlu diakui.

- Ketidakseimbangan kelas yang ekstrem. Distribusi label pada dataset sangat timpang: kelas *Neutral* mendominasi sekitar 73.8% dari total data, sementara kelas *Victim Blaming* hanya mewakili sekitar 3.4%. Kondisi ini memiliki konsekuensi langsung yang terukur: meskipun *class weighting* diterapkan di

semua model, tidak ada satu pun model yang berhasil mencapai recall *Victim Blaming* di atas 0.50 dan mayoritas model menghasilkan recall di bawah 0.20 untuk kelas ini. Balanced accuracy seluruh model berkisar antara 0.42–0.57, jauh di bawah accuracy keseluruhan yang tampak tinggi (0.70–0.80), mengungkap bahwa performa tinggi itu sebagian besar disumbang oleh kemampuan mengenali kelas *Neutral* yang dominan. Tanpa penanganan *imbalance* yang lebih agresif, seperti *oversampling* (SMOTE), augmentasi data, atau pengumpulan lebih banyak sampel kelas minoritas performa pada kelas yang paling relevan secara sosial ini sulit ditingkatkan secara signifikan.

- Kegagalan konvergen BiLSTM+Attention. Model BiLSTM dengan mekanisme Attention mengalami kegagalan konvergen total: *training* berhenti di epoch ke-4 karena *EarlyStopping* terpicu, menghasilkan F1-macro 0.0955 dengan 96% prediksi terpusat ke satu kelas. *Confusion matrix* mengkonfirmasi ini pada 212 dari 220 sampel *Neutral*, seluruh 10 sampel *Victim Blaming*, dan 36 dari 42 sampel *Advocacy* semuanya salah diprediksi sebagai *Supportive*. Kurva *training* menunjukkan *validation accuracy* yang kolaps sementara *training accuracy* masih naik yang berarti tanda jelas *overfitting* berat sejak awal. Kondisi ini kemungkinan besar disebabkan oleh kombinasi dataset kecil, *imbalance* ekstrem, *learning rate* yang terlalu tinggi ($1e-3$) untuk arsitektur *attention*, dan jumlah parameter yang terlalu besar *relative* terhadap ukuran data. Hasil ini tidak dapat diinterpretasikan sebagai representasi kemampuan mekanisme attention secara umum.
- Kosakata tidak baku dan noise dari media sosial. Dataset bersumber dari komentar TikTok dan YouTube yang karakteristiknya berbeda secara signifikan dari teks Twitter yang menjadi basis *pre-training* IndoBERT dan IndoBERTweet. Komentar dari kedua platform ini kerap mengandung singkatan non-standar, *typo* yang tidak konsisten, campur kode (*code-switching*) Bahasa Indonesia–Jawa–Inggris, ekspresi slang yang sangat lokal, serta fragmen kalimat yang tidak gramatikal. Meskipun normalisasi slang dan *stopword removal* sudah diterapkan, banyak ekspresi yang tidak tercakup dalam daftar yang ada membuat sebagian teks menjadi representasi yang kurang informatif bagi model, khususnya untuk ML klasik yang bergantung pada kecocokan leksem.

- Cakupan *victim-blaming lexicon* masih sempit. Lexicon 15 kata yang dikembangkan hanya menangkap ekspresi *victim blaming* yang eksplisit dan langsung. Ekspresi yang bersifat implisit, seperti pertanyaan retorik, ironi, atau framing halus yang menyalahkan korban tanpa menyebut kata-kata dalam lexicon yang tidak tertangkap. Ini menjelaskan mengapa bahkan SVM+VB Lexicon, meskipun terbaik di antara model ML klasik untuk kelas *Victim Blaming*, hanya mencapai recall 0.30 dengan 7 dari 10 sampel *Victim Blaming* tetap salah diklasifikasikan.
- Generalisasi lintas platform terbatas. Seluruh data bersumber dari dua platform dengan karakteristik audiens dan norma komunikasi yang berbeda (TikTok dan YouTube), dan belum diuji pada platform lain seperti X/Twitter atau Instagram. Pola bahasa yang digunakan untuk mengekspresikan stance dalam komentar video pendek TikTok bisa berbeda dari diskusi panjang di kolom komentar YouTube, sehingga performa model pada data dari platform yang belum dilihat selama training perlu diverifikasi tersendiri.

5. Kesimpulan

Penelitian kami membandingkan delapan model dari tiga paradigma NLP untuk mendeteksi *stance* dan Victim Blaming pada opini publik Indonesia terkait kasus kekerasan seksual di media sosial. Dataset berlabel empat kelas yaitu *Supportive*, *Victim Blaming*, *Neutral*, *Advocacy* dengan distribusi yang sangat tidak seimbang menjadi tantangan utama sepanjang eksperimen.

Dari sisi performa keseluruhan, IndoBERTweet adalah pilihan terbaik. Dengan F1-macro 0.5708, accuracy 0.7967, balanced accuracy 0.5648, dan Cohen's Kappa 0.5216, model ini secara konsisten unggul di semua metrik. Keunggulannya atas IndoBERT Base mencapai 5.4 poin F1-macro, dan selisih terbesarnya ada di kelas Advocacy (F1 0.705 vs 0.582), hal ini mencerminkan relevansi pre-training berbasis Twitter untuk domain media sosial informal berbahasa Indonesia.

Dua temuan di luar dugaan memberi *insight* tersendiri pada penelitian ini. Pertama, BiLSTM tanpa attention (F1-macro 0.5305) mengungguli IndoBERT Base dan mencatat recall Victim Blaming tertinggi di antara semua model (0.50), menunjukkan bahwa pada

data skala kecil dengan imbalance parah, model sederhana yang dilatih langsung pada domain kadang lebih efektif untuk kelas minoritas. Kedua, SVM+VB Lexicon (F1-macro 0.5212) melampaui IndoBERT Base, membuktikan bahwa lexicon berbasis domain yang dirancang secara targeted walaupun terdiri dari hanya 15 kata, tetap relevan dan kompetitif bahkan terhadap model Transformer berskala besar, khususnya ketika data kelas target sangat terbatas. Sebaliknya, BiLSTM+Attention gagal total akibat kegagalan konvergen, menghasilkan F1-macro 0.0955 dan tidak dapat dibandingkan dengan model lain dalam eksperimen ini.

Keterbatasan terbesar penelitian ini bukan pada pilihan modelnya, melainkan pada datanya. Kelas *Victim Blaming* yang hanya mewakili sekitar 3.4% dari total dataset membuat tidak ada satu pun model yang bisa mendeteksinya secara andal, bahkan setelah *class weighting* diterapkan. Komentar dari TikTok dan YouTube yang penuh *noise*, *slang* tidak baku, dan campur kode juga menambah kesulitan representasi bagi semua model. Untuk penelitian lanjutan, prioritas utama seharusnya ada pada pengumpulan lebih banyak sampel kelas *Victim Blaming*, perluasan *lexicon* untuk menangkap ekspresi implisit dan ironis, serta eksplorasi teknik augmentasi data atau *threshold adjustment* agar sensitivitas terhadap kelas minoritas yang paling krusial secara sosial ini dapat ditingkatkan secara nyata.

Daftar Pusaka

1. A. C. Sari et al., "Comparative Analysis of LSTM and BiLSTM for Sexual Harassment Classification on Indonesian Social Media," 2024 7th International Seminar on Research of Information Technology and Intelligent Systems (ISRITI), Yogyakarta, Indonesia, 2024.
2. Q. Jiale, S. N. Huda Sheikh Abdullah, M. Mohd, A. H. Shaari and R. Haoda, "Cyber Cross-Lingual Sentiment Analysis Model Based On Deep Learning Methods," 2025 3rd International Conference on Cyber Resilience (ICCR), Dubai, United Arab Emirates, 2025.
3. C. Amanda, I. Jaya and D. Arisandi, "Identification of Sexual Harassment in Social Media Comments Using IndoBERT and Support Vector Machine," 2024 8th International Conference on Electrical, Telecommunication and Computer Engineering (ELTICOM), Medan, Indonesia, 2024.

Lampiran

a) Cek Penggunaan AI

Your File Content is Human written

0%

AI GPT*

TF-IDF (Naive Bayes dan SVM)
TfidfVectorizer diatur dengan parameter max_features = 5000 dan ngram_range = (1,2) sehingga menghasilkan unigram dan bigram. Vectorizer dilatih hanya di data training dan ditransformasi ke data validasi untuk menghindari terjadinya data leakage.

Tiga kategori emosi dibuat dengan lexicon manual, yaitu kategori marah yang terdiri dari kata seperti marah, bejat, biadab, hancur, benci, emosi, kecewa, dendam, jengkel, dan tega. Kategori sedih terdiri dari kata seperti sedih, minis, kasihan, trauma, menangis, duka, prihatin, nyesek, sakit hati, dan nyelekit. Kategori takut yang terdiri dari kata takut, ngeri, ancam, waspada, khawatir, dan hati-hati. Proses ekstraksi fitur dilakukan dengan menghitung jumlah kemunculan substring dari setiap kata dalam lexicon pada teks. Perhitungan menghasilkan vektor dimensi tiga yang memunculkan masing-masing kategori emosi, kemudian metode hstack digunakan untuk menggabungkan dengan matriks TF-IDF

Victim-Blaming Lexicon Feature (SVM + VB Lexicon)
Lexicon victim blaming terdiri dari 15 kata, yaitu pakain, baju, ketat, salahnya, godain, malam, sendirian, terbuka, provokatif, rok, goda, rayuan, salah sendiri, minta, dan wajar. Proses ekstraksi fitur dihitung dengan jumlah kemunculan kata victim blaming di teks dan menghasilkan skor tunggal vektor dimensi satu, setelah itu metode hstack digunakan untuk menggabungkan vektor tersebut.

Penanganan Class Imbalance (semua model)
Semua model menggunakan class weighting untuk menjaga keseimbangan distribusi semua label. Pada model SVM digunakan parameter class_weight='balanced' pada konstruktor SVC. Pada model BiLSTM digunakan fungsi compute_class_weight(class_weight='balanced') dari scikit-learn, dan hasilnya diberikan sebagai parameter class_weight pada proses model.fit(). Pada model IndoBERT dan IndoBERTweet digunakan compute_class_weight dari scikit-learn dan diubah menjadi torch.tensor dengan tipe torch.float. Bobot tersebut dipakai di dalam CustomTrainer yang melakukan override terhadap fungsi compute_loss menggunakan nn.CrossEntropyLoss(weight=weight).

Arsitektur Model

ComplementNB + TF-IDF
ComplementNB digunakan untuk model baseline dari NaiveBayes. Jika dibandingkan dengan MultinomialNB, metode ini lebih tahan terhadap distribusi kelas yang tidak seimbang (data imbalanced) karena estimasi parameternya dihitung dengan komplemen dari masing-masing kelas.

SVM Linear + Variasi Fitur
Scikit-Learn SVC dengan parameter kernel='linear' dan class_weight='balanced' dioptimalkan memakai GridSearchCV dengan cv=3 dan scoring='f1_macro'. Pencarian parameter dilakukan dengan nilai c = [0.01, 0.1, 1, 10]. GridSearchCV diproses secara terpisah pada tiga bagian yaitu hanya menggunakan TF-

b) Cek Plagiarism

TECHNICAL REPORT UNITY.pdf

Diunggah pada May 15, 2026, 1:42 PM

Unduh Hasil

7%

Similarity Score